

CASCO ზარალის ღირებულებისა და ანდერაითინგის ტარიფის მოდელი

TBC დაზღვევა — ტექნიკური ამოცანა · პროექტის სრული პრეზენტაცია

სფერო: ავტომობილის (CASCO) დაზღვევა · **ორი ნაწილი:** A — სეგმენტის რეიტინგი · B — გაფართოებული GLM/GBM **ტესტები:** 48 ტესტი · 11 მოდული · 0 ჩავარდნა · **ენები:** ინგლისური + ქართული (KA)

გეგმა

- ბიზნეს პრობლემა და მიზნები
- მონაცემთა წყაროები და სტრუქტურა
- ამოხსნის არქიტექტურა (კონვეიერი)
- ნაწილი A — სეგმენტის გამოცდილებით-რეიტინგი
- ნაწილი B — გაფართოებული სტატისტიკური მოდელები
- მთავარი მოდელების გადაწყვეტილებები და „რატომ“
- ინჟინერიის სიმყარე: ტესტები, EDA, ექსპერიმენტები
- რა შევამოწმეთ (სრული მატრიცა)
- შედეგები, აღმოჩენები და ინსაიტები
- დასკვნა და შემდეგი ნაბიჯები

1 · ბიზნეს პრობლემა და მიზნები

CASCO არის ავტომობილის ყოვლისმომცველი დაზღვევა. წიგნი არასაკმარისად არის ტარიფიკებული: პორტუგალიის ზარალიანობა შეადგენს 70.6% 60%-იანი მენეჯმენტის სამიზნესთან შედარებით — ეს არის დაახლოებით 18%-იანი საშუალო ნაკლებად-ტარიფიკება.

ზარალიანობა (LR) = განხორციელებული ზარალები ÷ მიღებული პრემია. **სუფთა პრემია** ფასავს $E[\text{cost}] = E[N] \cdot E[S]$, სადაც N = ზარალის რაოდენობა (სიხშირე), ხოლო S = ზარალის თანხა (სიმძიმე). **ტექნიკური პრემია** = $\text{model_pp} / \text{target_LR}$.

მიზანი	რას აწვდით
დიაგნოსტიკა	წიგნის დაყოფა 4 რეიტინგის განზომილებაზე: 70.6%-ის გამომწვევი ცხელი/ცივი სეგმენტების გამოვლენა.
ინდიკაცია	კრედიტიზაციით წონითდებული, შეზღუდული ($\pm 50\%$) ტარიფის კორექციები სამიზნე ზარალიანობის წინაშე.
მოდელირება	ინდივიდუალურ-რისკის სიხშირის $\times$ სიმძიმის მოდელები, რომლებიც დროით გარეთ არიან ვალიდირებული, ტარიფის ინდიკაციით + ელასტიურობით.

2 · მონაცემთა წყაროები და სქემა

ყველა ნედლი შემავალი ინახება `data/` -ში; ერთი სანდო გაშენდა/გაერთიანების ფენა (`src/load_data.py`) ქმნის ერთ მონაცემთა ჩარჩოს პოლისის დონეზე.

ფაილი	როლი	ძირითადი შემცველობა
<code>Policies_1805_v4.csv</code>	პოლისების მასტერი	პრემია, დაზღვეული თანხა, ავტომობილი, მძღოლის ასაკი, ძალის შესვლა, ფრანშიზა
<code>Claims_1805_v2.csv</code>	ზარალები	ზარალის თანხები, თარიღები, დაკავშირებული პოლისი
<code>Clients_1805_v3.csv</code>	კლიენტები	კლიენტის ტიპი (ფიზიკური/იურიდიული), პირადი გამოყენება
<code>enrcols.csv</code>	გამდიდრება	ფრანშიზის კატეგორია, რენტაბელური მძღოლების რაოდენობა, მინ. მძღოლის ასაკი, ავტომობილის ასაკი
<code>franchise_field_categories.csv</code>	ლუქაფი	ფრანშიზის კატეგორიის მაპინგი
<code>fx_rates.csv</code>	ვალუტა	კონვერტაცია GEL-ში (USD → GEL)

გაშენდის წესები: მხოლოდ CASCO + ფიზიკური + პირადი გამოყენება; ზარალების ვალიდაცია; დაზღვეული თანხის GEL-ში კონვერტაცია; `earned_premium` -ის გამოთვლა; ზარალების აგრეგირება პოლისის მიხედვით (ნულებით შევსება); `loss_ratio` მხოლოდ სადაც `earned_premium > 0` (უსაფრთხო გაყოფა → NaN); `exposure = earned_premium.clip(lower=0)` (GLM ოფსეტი / GBM წონა); გამდიდრება `deductible_type`, `eligible_driver_count`, `min_driver_age`, `carage` -ით.

ეს ერთი ფენა არის ერთადერთი ადგილი, სადაც ნედლი მონაცემები ეხება — ყველა შემდგომი მოდული იგივე წმინდა ჩარჩოს მოიხმარს, ამიტომ ცვლილებები წინასწარმეტყველად კასკადურდება.

3 · ამოხსნის არქიტექტურა

ორი თანამშრომელი ნაწილი იზიარებს გაშენდილ ჩარჩოს. ნაწილი A = სწრაფი, განმარტვადი სეგმენტური ხედი; ნაწილი B = ინდივიდუალურ-რისკის მოდელები, რომლებიც დროით გარეთ არიან ვალიდირებული.

ნაწილი A — სეგმენტის გამოცდილებით-რეიტინგი (`run.py` კოორდინაციას უწევს):

`load_data` → `segments` → `metrics` → `recommend` → `run` (CSV + Excel)

ნაწილი B — გაფართოებული ინდივიდუალურ-რისკის მოდელები: `features` → `frequency`

→ `severity` → `pure_premium` → `credibility` → `pricing` → `validation`

- დროზე დაფუძნებული გაყოფა:** ტრენინგი `efdate < 2025-01-01`, ტესტი `efdate ≥ 2025-01-01` (გაჟონვის თავიდან აცილება).
- ექსპოზიცია როგორც ოფსეტი:** `offset = log(exposure)`, სადაც `exposure = earned_premium`; ხელახლა გამოიყენება პროგნოზის დროს.

- **გამონატანები:** 1,264 სეგმენტი, პორტფელის შეჯამება, 6 დაშლის ფურცელი, მოდელის მეტრიკები და მონიტორინგის ცხრილები.

4 · ნაწილი A — სეგმენტის გამოცდილებით-რეიტინგი

სეგმენტაცია (segments.py) — ოთხი რეიტინგის განზომილება, შეკუმშული

სტაბილურობისთვის: - **ასაკი:** 18–20 · 21–25 · 26–29 · 30–40 · >40 - **ავტომობილის ტიპი:** მაღალი გამავლობის · სედანი · კუპე/კაბრიო (შეკუმშული 3-ში) - **ფრანშიზა:** კი / არა - **დაზღვეული თანხა:** USD დიაპაზონები დავალებიდან ($\leq 5k$ · 1k-იანი ბიჯით $5k-50k$ · $> 50k$)

→ 1,264 შედგენილი სეგმენტი.

მეტრიკები (metrics.py): aggregate_by თვლის სეგმენტის LR/რეიტს/სიხშირეს/სიმძიმეს; safe_div აბრუნებს NaN-ს (არა ∞) ნულოვან ექსპოზიციაზე; aggregate_overall იძლევა პორტფელის ჯამებს.

რეკომენდაციები (recommend.py): კორექცია = კრედიბილურობით წონითდებული

გამოცდილება target_loss_ratio = 0.60 -ის წინაშე; შეზღუდული $\pm 50\%$; თხე სეგმენტები

შემცირდება საშუალოსკენ კრედიბილურობით z ; მოქმედების ლეიბელი (გაზრდა/შემცირება/შენარჩუნება) ემატება.

ყველა კორექცია არის წერტილოვანი შეფასება, რომელიც იგნორირებს ელასტიურობას — დოკუმენტირებული შეზღუდვა.

5 · ნაწილი B — გაფართოებული სტატისტიკური მოდელები

- **სიხშირე (frequency.py):** Poisson-ისა და NegBin GLM offset = $\log(\text{exposure})$ -ით; LightGBM Poisson GBM იყენებს log_exposure ფიჩერად; NegBin იწყება Poisson MLE-დან $\alpha=0.1$ -ით (არასდროს 0 → თავიდან იცილებს $\log(0)$ BFGS გაფუჭებას); **ოფსეტი ხელახლა გამოიყენება პროგნოზში.**
- **სიმძიმე (severity.py):** მოდელირებს თანხას ერთ ზარალზე; LogNormal GLM + LightGBM Gamma GBM; **Gamma GLM მოიხსნა** (IRLS/BFGS იშლება მძიმე კუდზე).
- **სუფთა პრემია (pure_premium.py):** $E[\text{cost}] = E[N] \cdot E[S]$ — მრავლობითი Poisson×LogNormal და პირდაპირი Tweedie (ძალა 1.5) incurred_claim -ზე; calibration_factor = $\text{mean}(\text{actual } \$) / \text{mean}(\text{predicted } \$)$.
- **კრედიბილურობა (credibility.py):** Bühlmann-Straub $Z_i = n_i / (n_i + k)$, $k = EPV / VPP$; n_i = **პოლისების რაოდენობა** (არა დოლარის ექსპოზიცია); ამცირებს დაკვირვებულ სუფთა პრემიას პორტფელის საშუალოსკენ.
- **ტარიფიკაცია (pricing.py):** ტექნიკური პრემია = $\text{model_pp} / \text{target_LR}$ (0.65 ნაწილი B-ში); ტარიფის ცვლილება შეზღუდული $\pm 50\%$ -ით; ელასტიურობაზე დაფუძნებული მოცულობის რეაქცია (-0.5); კალიბრაციის ფაქტორი ინდიკაციამდე.
- **ვალიდაცია (validation.py):** ყოველთვიური ფაქტიკური-საპირისპირო-პროგნოზირებული LR მონიტორინგი hold-out-ზე; დროით გარეთ სადაზღვევო Gini; დონის კალიბრაციის შემოწმება (კოეფ. ≈ 1.0).

6 · მთავარი მოდელირების გადაწყვეტილებები და „რატომ“

გადაწყვეტილება	რატომ
დროზე დაფუძნებული გაყოფა (არა შემთხვევითი)	შემთხვევითი გაყოფა აჟონებს მომავალ პოლისებს ტრენინგში და ზრდის Gini-ს.
<code>offset = log(earned_premium)</code>	სტანდარტიზაცია ექსპოზიციის ერთეულზე; ხელახლა გამოყენება პროგნოზის დროს საჭიროა, თუ არა — მოდელი რეიტის×ექსპოზიციას წინასწარმეტყველებს.
Gamma GLM-ის მოხსნა სიმძიმისთვის	IRLS/BFGS იშლება მძიმე კუდზე; LogNormal GLM + Gamma GBM სტაბილურია.
მრავლობითი <code>freq×sev</code> და Tweedie	ახსნის ღირებულების მძრავს + გადასასწორებელ შემოწმებას იძლევა; Tweedie ნატურალურად მოდელირებს ნულ-ინფლაციურ ზარალებს.
კრედიტილობა იყენებს პოლისების რაოდენობას <code>n</code>	დოლარის ექსპოზიცია ყველა სეგმენტს „სრულად კრედიტილურს“ განდის; რაოდენობა ასახავს რეალურ მოცულობას.
±50% ზღვარი + კრედიტილობა	თავიდან იცილებს თხე სეგმენტების დესტაბილიზაციას.
კალიბრაციის ფაქტორი ინდიკაციამდე	მრავლობითი მოდელი ნაკლებად პროგნოზირებს საშუალო PP-ს (ფაქტორი ≈ 1.68); ასწორებს დონეს, არა ფორმას.
ორი სამიზნე LR (0.60 / 0.65)	ცალკე მენეჯმენტის პარამეტრები; ორივე დასაყენი განთავსებამდე.

7 · ინჟინერიის სიმყარე — ტესტები, EDA, ექსპერიმენტები

მოდელი, რომელსაც ვერ გაიმეორებთ და ვერ დაიცავთ, გამშვები არ არის.

- **ტესტები (`tests/`):** 48 ტესტი · 11 მოდული · 0 ჩავარდნა. ყოველი ფაილი ადოკუმენტებს რატომ არსებობს; ნაკრებმა უკვე დაიჭირა NegBin `alpha=0` გადახრა (20-წუთიანი დაბლოკვა) და ექსპერიმენტების `KeyError: 'segment'`.
- **EDA (`src/eda.py`):** 9-ნაბიჯიანი ფუნქცია (მიმოხილვა, სიხშირე, სიმძიმე, ექსპოზიცია, სეგმენტები, დროის ტრენდი, ფიჩერის ურთიერთობები, ნულოვანი ზარალის ანალიზი, კრედიტილობა) — თითოეული აჩვენებს ფაქტებს.
- **ექსპერიმენტები (`src/experiments.py`):** 8 what-if გამოძიება, რომელიც ამტკიცებს თითოეულ არჩევანს: Gamma GLM გადახრა (EXP 2), `log_exposure` აბლაცია (EXP 5), პოლისის რაოდენობა პირისპირ დოლარის კრედიტილობას (EXP 6), კალიბრაციის ეფექტი ინდიკაციის ნიშნის შემობრუნებით (EXP 7), NegBin პირისპირ Poisson (EXP 8).

პროცესის წესი: ნებისმიერი ცვლილება `load_data.py` -ში, მოდელში ან მეტრიკაში მზადაა მხოლოდ მაშინ, როცა `python -m tests.run_all` მწვანეა და `python -m src.experiments` ჯერ კიდევ სრულდება.

8 · რა შევამოწმეთ — სრული მატრიცა

მოდული	# ტესტი	ემტკიცება
test_load_data	8	პოლისის დონე და არაცარიელი; მხოლოდ CASCO; ფიზიკური; პირადი; დადებითი უსასრულო SI; ზარალები აგრეგირებული ნულებით; ფრანშიზა კი/არა; LR მხოლოდ სადაც earned>0
test_segments	5	4 განზომილება; ასაკის ხვრელი არაა; ფრანშიზა ბინარული; ავტომობილი 3+-ში; გასაღები უნიკალური
test_metrics	4	safe_div → NaN არაა; ძირითადი მეტრიკები; შიგნით თანმიმდევრული; ცნობილი პორტფელის LR
test_recommend	5	კორექციები ზღვარში; კრედიტილობა [0,1]; ამცირებს თხე სეგმენტებს; ცხელი +კორექცია; ლეიბელი თანხვედრაში
test_features	5	დროის გაყოფა ზედაპირის გარეშე და კვეთს cutoff-ს; y_sev მხოლოდ სადაც ზარალი; ინჟინერია; ზომები; ექსპოზიცია ≥ 0
test_frequency	4	Poisson გადახრა ≥ 0 ; ოფსეტი ხელახლა პროგნოზში; train/evaluate მუშაობს და განასხვავებს
test_severity	4	მუდმივის Gini = 0; Gamma გადახრა ≥ 0 ; ნულები არა; train/evaluate მუშაობს
test_pure_premium	4	Tweedie გადახრა ≥ 0 ; კალიბრაცია გონივრული; პროგნოზი ექსპოზიციასთან; განასხვავებს
test_credibility	3	Z [0,1] და k>0; საშუალო Z რეალურ შემცირებას აჩვენებს; შერეული Gini უკეთესია
test_pricing	3	ტარიფის ცვლილება შეზღუდული; მოცულობა = ელასტიურობა × ცვლილება; ინდიკაცია დადებითი
test_validation	3	რეპორტის ფორმა და სვეტები; hold-out Gini > 0; დონის კალიბრაცია ≈ 1
ჯამში	48	11 მოდული · 0 ჩავარდნა

9 · შედეგები, აღმოჩენები და ინსაიტები

პორტფელი (ნაწილი A): LR 70.6% (სამიზნე 60%-თან) · 119,745 პოლისი · მიღებული პრემია **GEL 172.4M** · განხორციელებული **GEL 121.7M**.

მოდელის დისკრიმინაცია (დროით გარეთ, ნაწილი B):

მოდელი	Gini	შენიშვნა
სიხშირე — Poisson GLM	0.3909	საბაზისო GLM
სიხშირე — LightGBM (Poisson)	0.4085	სჭრიფს GLM-ებს
სიმძიმე — LogNormal GLM	0.2664	ინტერპრეტირებადი ბაზისი
სუფთა პრემია — Freq×Sev (GLM)	0.4086	ყველაზე ძლიერი რანჟირებული
სუფთა პრემია — Tweedie GBM	0.3555	კონკურენტუნარიანი გადახრაზე
კრედიტილობა — შერეული	0.0805	ნედლი 0.0678-ის ნაცვლად

მთავარი ინსაიტები: - ახალგაზრდა მძღოლები (21–29) ყველაზე ცუდები არიან ზარალიანობით და უკვე უხდებიან ყველაზე მაღალ პოლის-თითო რეიტს (~2x 40+-ის) — წიგნი მაინც კარგავს ფულს. - ფრანშიზის გარეშე პოლისები ~19 პუნქტით უარესი (0.743 პირისპირ 0.555) იგივე საშუალო რეიტთან — ფრანშიზა არ არის ტარიფიკებული. - დაბალი დაზღვეული თანხის ავტომობილები ყველაზე ნაკლებად ფასდება; რეიტის მრუდი ინვერსიულია რისკის მიმართ. - ტესტის კალიბრაცია: ფაქტიკური LR 0.8225 პირისპირ პროგნოზირებულ 0.7838 (სამიზნე 0.65) → კარგად კალიბრირებული დონეში (~1.05); წიგნი ~17–22%-ით სამიზნეზე ზემოთ. - საშუალო ინდიცირებული ტარიფის ცვლილება +18.5%; მოცულობა -9.3%; 22,505 პოლისი 1, 5,735 ↓.

10 · დასკვნა და შემდეგი ნაბიჯები

მოეწოდა: განმარტვადი სეგმენტის რეიტინგი (1,264 სეგმენტი) + მოდელზე დაფუძნებული ინდივიდუალურ-რისკის ტარიფიკაცია; დროით გარეთ ვალიდირებული, სრული ტესტის/EDA/ექსპერიმენტის ჩარჩოთი; სრული ქართული თარგმანი, გადასინჯული და ვერიფიცირებული (0 ტესტის ჩავარდნა).

შემდეგი ნაბიჯები: 1. დააყენეთ მენეჯმენტის სამიზნე ზარალიანობები (ხარჯები + მოგების დატვირთვა) განთავსებამდე. 2. კალიბრირეთ სრული კრედიტილურობის სტანდარტი პორტფელის ცვალებადობაზე. 3. დაავალიდირეთ კორექციები hold-out პერიოდზე; სიმულირეთ პრემია/LR რეაქცია. 4. განათავსეთ validation.py მონიტორინგის დაფა; უკანა-ტესტი ინდიკაციის რეალიზებულ LR-სთან. 5. განიხილეთ GLMM / boosted ჰიბრიდი და სწორი Tweedie-ს ძალის ძებნა.

ძირითადი დასკვნა: წიგნი ~18%-ით არის ნაკლებად ტარიფიკებული; მოდელი ხსნის სად (ახალგაზრდა მძღოლები, ფრანშიზის გარეშე, დაბალი დაზღვეული თანხა) და მიუთითებს რისკ-ადეკვატურ, კრედიტილურობით შეზღუდულ კორექციებს — გამეორებადი, ტესტირებული და დოკუმენტირებული ინგლისურადაც და ქართულადაც.

CASCO ზარალის ღირებულებისა და ანდერაითინგის ტარიფის მოდელი — პროექტის პრეზენტაცია · ტესტები: 48 · 11 მოდული · 0 ჩავარდნა · EN + KA